

zad08-linear-rnn

November 27, 2025

1 Zajęcie 08: Liniowe RNN - Sumowanie Sekwencji

1.1 Wstęp

Celem zadania jest implementacja liniowej rekurencyjnej sieci neuronowej (Linear RNN) do sumowania sekwencji liczb.

Architektura RNN:

$$S_k = S_{k-1} \cdot W_{rec} + X_k \cdot W_x$$

gdzie: - S_k - stan w kroku czasowym k - X_k - wejście w kroku k - W_x - wagi wejściowe - W_{rec} - wagi rekurencyjne

```
[1]: import numpy as np
import matplotlib.pyplot as plt
from matplotlib import cm
from matplotlib.colors import LogNorm

np.random.seed(seed=42)
```

1.2 Tworzenie zbioru danych

Dane wejściowe składają się z 30 sekwencji po 20 kroków czasowych każda. Każda sekwencja jest generowana z jednolitego rozkładu losowego zaokrąglonego do $\{0, 0.5, 1\}$. Cel: suma liczb w sekwencji.

```
[2]: # Parametry zbioru danych
nb_of_samples = 30
sequence_len = 20

# Tworzenie sekwencji wejściowych
# Wartości losowe zaokrąglane do 0, 0.5 lub 1
X = np.round(np.random.rand(nb_of_samples, sequence_len) * 2) / 2

# Tworzenie celów - suma każdej sekwencji
t = np.sum(X, axis=1)

print(f"Wymiary danych:")
print(f" X (wejście): {X.shape}")
```

```

print(f" t (cele): {t.shape}")
print(f"\nPierwsza sekwencja:")
print(f" X[0] = {X[0]}")
print(f" Suma = {t[0]}")
print(f"\nStatystyka sum:")
print(f" Min: {t.min():.1f}")
print(f" Max: {t.max():.1f}")
print(f" Średnia: {t.mean():.2f}")

```

Wymiary danych:

```

X (wejście): (30, 20)
t (cele): (30,)

```

Pierwsza sekwencja:

```

X[0] = [0.5 1. 0.5 0.5 0. 0. 0. 1. 0.5 0.5 0. 1. 1. 0. 0. 0. 0. 0.5
0.5
0.5 0.5]
Suma = 8.5

```

Statystyka sum:

```

Min: 6.0
Max: 14.0
Średnia: 10.10

```

1.3 Implementacja Linear RNN

1.3.1 Forward Pass

```
[3]: def update_state(xk, sk, wx, wRec):
    """
    Aktualizacja stanu: S_k = S_{k-1} * W_rec + X_k * W_x

    Args:
        xk: wejście w kroku k
        sk: stan poprzedni
        wx: wagi wejściowe
        wRec: wagi rekurencyjne
    """
    return xk * wx + sk * wRec

def forward_states(X, wx, wRec):
    """
    Rozwiń sieć i oblicz wszystkie aktywacje stanów.

    Args:
        X: macierz wejścia (nb_samples, sequence_len)
        wx: wagi wejściowe
    """

```

```

wRec: wagi rekurencyjne

>Returns:
S: macierz stanów (nb_samples, sequence_len+1)
S[:, 0] - stan początkowy (0)
S[:, -1] - ostateczne wyjście
"""

S = np.zeros((X.shape[0], X.shape[1] + 1))
for k in range(X.shape[1]):
    S[:, k+1] = update_state(X[:, k], S[:, k], wx, wRec)
return S

def loss(y, t):
    """Błąd MSE między przewidywaniem y a celem t"""
    return np.mean((t - y)**2)

# Test forward pass
wx_test = 1.0
wRec_test = 0.5

S_test = forward_states(X, wx_test, wRec_test)
output_test = S_test[:, -1]
loss_test = loss(output_test, t)

print(f"\nTest forward pass:")
print(f"  wx={wx_test}, wRec={wRec_test}")
print(f"  Wymiary S: {S_test.shape}")
print(f"  Wymiary wyjścia: {output_test.shape}")
print(f"  Strata początkowa: {loss_test:.6f}")

```

```

Test forward pass:
wx=1.0, wRec=0.5
Wymiary S: (30, 21)
Wymiary wyjścia: (30,)
Strata początkowa: 87.405371

```

1.3.2 Backward Pass - Backpropagation Through Time (BPTT)

```

[4]: def output_gradient(y, t):
    """Gradient straty MSE względem wyjścia"""
    return 2.0 * (y - t)

def backward_gradient(X, S, grad_out, wRec):

```

```

"""
Propaguj gradient przez sieć w tył (BPTT).

Args:
    X: wejście (nb_samples, sequence_len)
    S: stany (nb_samples, sequence_len+1)
    grad_out: gradient przy wyjściu
    wRec: wagи rekurencyjne

Returns:
    (wx_grad, wRec_grad): gradienty wag
    grad_over_time: gradienty w każdym kroku czasowym
"""

# Inicjalizacja
grad_over_time = np.zeros((X.shape[0], X.shape[1] + 1))
grad_over_time[:, -1] = grad_out
wx_grad = 0
wRec_grad = 0

# Iteruj wstecz przez czas
for k in range(X.shape[1], 0, -1):
    # Akumuluj gradienty parametrów
    wx_grad += np.sum(np.mean(grad_over_time[:, k] * X[:, k-1], axis=0))
    wRec_grad += np.sum(np.mean(grad_over_time[:, k] * S[:, k-1], axis=0))
    # Propaguj gradient do poprzedniego stanu
    grad_over_time[:, k-1] = grad_over_time[:, k] * wRec

return (wx_grad, wRec_grad), grad_over_time

# Test backpropagation
S = forward_states(X, wx_test, wRec_test)
grad_out = output_gradient(S[:, -1], t)
backprop_grads, grad_over_time = backward_gradient(X, S, grad_out, wRec_test)

print(f"\nTest backpropagation:")
print(f"  wx_grad: {backprop_grads[0]:.6f}")
print(f"  wRec_grad: {backprop_grads[1]:.6f}")
print(f"  Wymiary grad_over_time: {grad_over_time.shape}")

```

```

Test backpropagation:
  wx_grad: -17.342351
  wRec_grad: -37.656358
  Wymiary grad_over_time: (30, 21)

```

1.4 Weryfikacja Gradientów

Porównanie gradientów obliczonych za pomocą backpropagation z gradientami numerycznymi:

```
[5]: # Weryfikacja gradientów
params = [1.2, 1.2]  # [wx, wRec]
eps = 1e-7

# Oblicz backprop gradienty
S = forward_states(X, params[0], params[1])
grad_out = output_gradient(S[:, -1], t)
backprop_grads, grad_over_time = backward_gradient(X, S, grad_out, params[1])

print("Weryfikacja gradientów (Gradient Checking):\n")
print(f"{'Parameter':<12} {'Backprop':<15} {'Numeryczny':<15} {'Różnica':<15}")
print("-" * 60)

# Sprawdzaj każdy parametr
for p_idx, param_name in enumerate(['wx', 'wRec']):
    grad_backprop = backprop_grads[p_idx]

    # + eps
    params[p_idx] += eps
    plus_loss = loss(forward_states(X, params[0], params[1])[:, -1], t)

    # - eps
    params[p_idx] -= 2 * eps
    min_loss = loss(forward_states(X, params[0], params[1])[:, -1], t)

    # Przywróć
    params[p_idx] += eps

    # Gradient numeryczny
    grad_num = (plus_loss - min_loss) / (2 * eps)

    # Porównanie
    diff = abs(grad_num - grad_backprop)
    print(f"{'param_name':<12} {"grad_backprop:<15.8f} {"grad_num:<15.8f} {"diff:<15.8e}")

    # Sprawdzenie
    if not np.isclose(grad_num, grad_backprop, atol=1e-5):
        print(f" Ostrzeżenie: Gradienty się nie zgadzają!")
    else:
        print(f" OK")
```

Weryfikacja gradientów (Gradient Checking):

Parameter	Backprop	Numeryczny	Różnica
wx	20646.91675951	20646.91674605	1.34672810e-05
OK			
wRec	301554.42167467	301554.42152136	1.53307745e-04
OK			

1.5 Wizualizacja Powierzchni Błędu

```
[6]: def get_loss_surface(w1_low, w1_high, w2_low, w2_high, nb_of_ws):
    """Oblicz powierzchnię błędu dla siatki wag"""
    w1 = np.linspace(w1_low, w1_high, num=nb_of_ws)
    w2 = np.linspace(w2_low, w2_high, num=nb_of_ws)
    ws1, ws2 = np.meshgrid(w1, w2)
    loss_ws = np.zeros((nb_of_ws, nb_of_ws))

    for i in range(nb_of_ws):
        for j in range(nb_of_ws):
            loss_ws[i, j] = loss(forward_states(X, ws1[i, j], ws2[i, j])[:, :-1], t)

    return ws1, ws2, loss_ws

# Oblicz powierzchnię błędu
print("Obliczanie powierzchni błędu... (to może chwilę potrwać)")
ws1, ws2, loss_ws = get_loss_surface(-2, 3, -2, 3, 40)

# Wizualizacja
fig = plt.figure(figsize=(14, 5))

# Lewa figura - przegląd
ax1 = fig.add_subplot(1, 2, 1)
contour1 = ax1.contourf(ws1, ws2, loss_ws + 1, levels=np.logspace(-0.5, 3, 30),
                        cmap=cm.viridis, norm=LogNorm())
ax1.set_xlabel('$w_x$ (wagi wejściowe)', fontsize=12)
ax1.set_ylabel('$w_{rec}$ (wagi rekurencyjne)', fontsize=12)
ax1.set_title('Powierzchnia błędu - Przegląd', fontsize=12)
ax1.grid(True, alpha=0.3)

# Prawa figura - zoom
ax2 = fig.add_subplot(1, 2, 2)
ws1_zoom, ws2_zoom, loss_ws_zoom = get_loss_surface(-0.5, 2, -0.5, 2, 40)
contour2 = ax2.contourf(ws1_zoom, ws2_zoom, loss_ws_zoom + 1,
                        levels=np.logspace(-0.5, 2, 30),
                        cmap=cm.viridis, norm=LogNorm())
ax2.set_xlabel('$w_x$', fontsize=12)
```

```

ax2.set_ylabel('$w_{rec}$', fontsize=12)
ax2.set_title('Powierzchnia błędu - Zoom', fontsize=12)
ax2.grid(True, alpha=0.3)

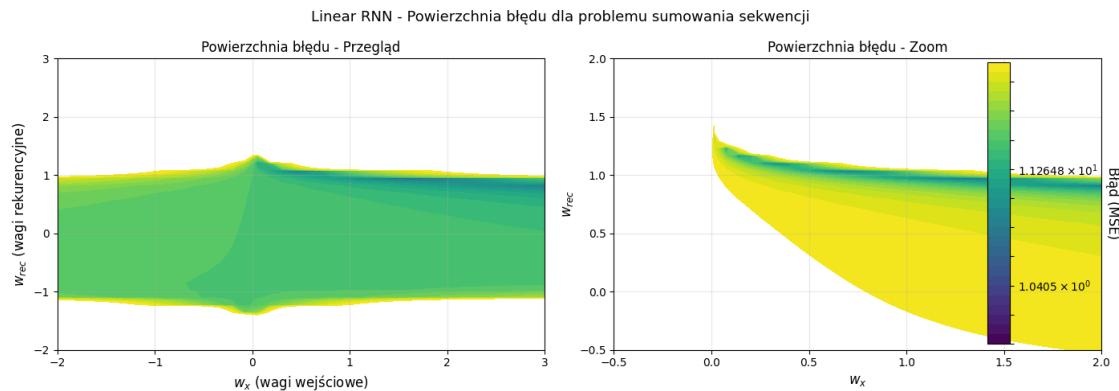
# Colorbar
fig.subplots_adjust(right=0.85)
cax = fig.add_axes([0.88, 0.15, 0.02, 0.7])
cbar = fig.colorbar(contour2, cax=cax)
cbar.set_label('Błąd (MSE)', fontsize=12, rotation=270, labelpad=20)

plt.suptitle('Linear RNN - Powierzchnia błędu dla problemu sumowania sekwencji', fontsize=13)
plt.tight_layout()
plt.show()

```

Obliczanie powierzchni błędu... (to może chwilę potrwać)

```
C:\Users\Maciek\AppData\Local\Temp\ipykernel_16424\3210053390.py:49:
UserWarning: This figure includes Axes that are not compatible with
tight_layout, so results might be incorrect.
plt.tight_layout()
```



1.6 Trening RNN - Gradient Descent

```
[7]: # Inicjalizacja wag
wx = 0.5
wRec = 0.5

# ZMNIEJSZONA stopa uczenia (było 0.01, co jest za dużo dla RNN bez clippingu)
learning_rate = 0.005
epochs = 400

# Historia treningu
```

```

loss_history = []
wx_history = [wx]
wRec_history = [wRec]

print(f"Trening Gradient Descent:")
print(f"  Stopa uczenia: {learning_rate}")
print(f"  Liczba epok: {epochs}")
print(f"  Początkowe wagi: wx={wx}, wRec={wRec}\n")
print(f"{'Epoka':<8} {'Strata':<12} {'wx':<12} {'wRec':<12} {'||grad||':<12}")
print("-" * 60)

for epoch in range(epochs):
    # Forward pass
    S = forward_states(X, wx, wRec)
    output = S[:, -1]
    loss_val = loss(output, t)

    # Backward pass
    grad_out = output_gradient(output, t)
    (wx_grad, wRec_grad), _ = backward_gradient(X, S, grad_out, wRec)

    # GRADIENT CLIPPING
    # Zapobiega wybuchającym gradientom poprzez ograniczenie ich normy
    grad_norm = np.sqrt(wx_grad**2 + wRec_grad**2)
    max_grad_norm = 5.0
    if grad_norm > max_grad_norm:
        wx_grad = wx_grad * max_grad_norm / grad_norm
        wRec_grad = wRec_grad * max_grad_norm / grad_norm

    # Aktualizacja wag
    wx = wx - learning_rate * wx_grad
    wRec = wRec - learning_rate * wRec_grad

    # Zbierz historię
    loss_history.append(loss_val)
    wx_history.append(wx)
    wRec_history.append(wRec)

    if epoch % 20 == 0 or epoch == epochs - 1:
        print(f"{'epoch':<8} {'loss_val':<12.6f} {'wx':<12.6f} {'wRec':<12.6f}" +
              f"{'grad_norm':<12.8f}")

print(f"\nTrening zakończony!")
print(f"  Finalna strata: {loss_history[-1]:.6f}")
print(f"  Finalne wagi: wx={wx:.6f}, wRec={wRec:.6f}")

```

Trening Gradient Descent:

Stopa uczenia: 0.005

Liczba epok: 400
 Początkowe wagi: wx=0.5, wRec=0.5

Epoka	Strata	wx	wRec	$\ grad\ $
0	96.352116	0.517022	0.518310	27.08885859
20	33.755229	0.713986	0.969906	435.89236793
40	1.943385	0.724086	1.018990	337.50617964
60	1.937897	0.726919	1.018612	336.89349832
80	1.932478	0.729736	1.018237	336.28636267
100	1.927129	0.732537	1.017865	335.68468498
120	1.921848	0.735324	1.017496	335.08837968
140	1.916633	0.738095	1.017131	334.49736331
160	1.911483	0.740851	1.016768	333.91155441
180	1.906397	0.743593	1.016408	333.33087349
200	1.901375	0.746320	1.016052	332.75524294
220	1.896415	0.749033	1.015698	332.18458698
240	1.891515	0.751731	1.015347	331.61883160
260	1.886676	0.754415	1.014999	331.05790450
280	1.881895	0.757085	1.014654	330.50173503
300	1.877172	0.759742	1.014312	329.95025418
320	1.872507	0.762384	1.013972	329.40339445
340	1.867897	0.765013	1.013635	328.86108989
360	1.863342	0.767628	1.013301	328.32327599
380	1.858841	0.770230	1.012969	327.78988965
399	1.697029	0.775839	1.037457	230.32657874

Trening zakończony!

Finalna strata: 1.697029
 Finalne wagi: wx=0.775839, wRec=1.037457

1.7 Wizualizacja Treningu

```
[8]: fig, axes = plt.subplots(2, 2, figsize=(14, 10))

# Wykres 1: Strata w funkcji epok
ax = axes[0, 0]
ax.plot(loss_history, 'b-', linewidth=2)
ax.set_xlabel('Epoka', fontsize=11)
ax.set_ylabel('Strata (MSE)', fontsize=11)
ax.set_title('Konwergencja straty', fontsize=12)
ax.grid(True, alpha=0.3)

# Wykres 2: Wagi w funkcji epok
ax = axes[0, 1]
ax.plot(wx_history, 'r-', label='$w_x$', linewidth=2)
ax.plot(wRec_history, 'b-', label='$w_{rec}$', linewidth=2)
```

```

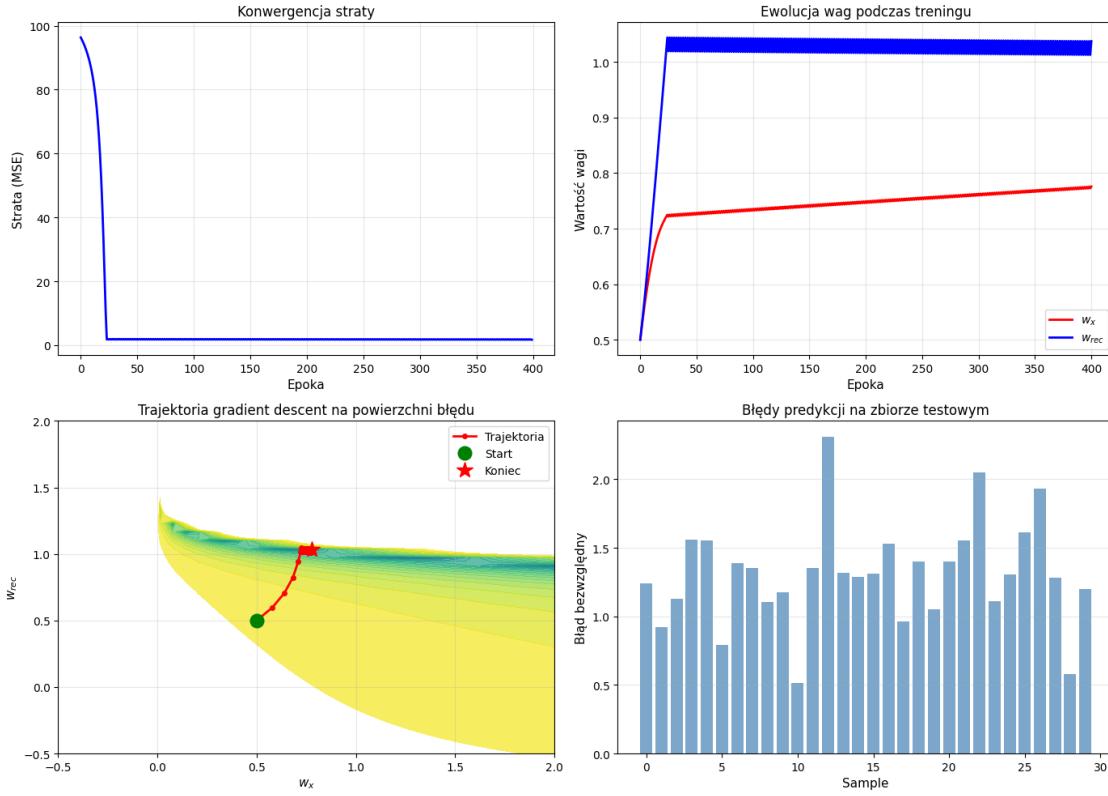
ax.set_xlabel('Epoka', fontsize=11)
ax.set_ylabel('Wartość wag', fontsize=11)
ax.set_title('Ewolucja wag podczas treningu', fontsize=12)
ax.legend(fontsize=10)
ax.grid(True, alpha=0.3)

# Wykres 3: Trajektoria w przestrzeni wag
ax = axes[1, 0]
ws1_traj, ws2_traj, loss_ws_traj = get_loss_surface(-0.5, 2, -0.5, 2, 40)
contour = ax.contourf(ws1_traj, ws2_traj, loss_ws_traj + 1,
                      levels=np.logspace(-0.5, 2, 30),
                      cmap=cm.viridis, norm=LogNorm(), alpha=0.7)
ax.plot(wx_history[::-5], wRec_history[::-5], 'r.-', linewidth=2, markersize=8, u
        ↪label='Trajektoria')
ax.plot(wx_history[0], wRec_history[0], 'go', markersize=12, label='Start')
ax.plot(wx_history[-1], wRec_history[-1], 'r*', markersize=15, label='Koniec')
ax.set_xlabel('$w_x$', fontsize=11)
ax.set_ylabel('$w_{rec}$', fontsize=11)
ax.set_title('Trajektoria gradient descent na powierzchni błędu', fontsize=12)
ax.legend(fontsize=10)
ax.grid(True, alpha=0.3)

# Wykres 4: Błąd predykcji
ax = axes[1, 1]
S_final = forward_states(X, wx, wRec)
y_pred = S_final[:, -1]
errors = np.abs(y_pred - t)
ax.bar(range(len(errors)), errors, color='steelblue', alpha=0.7)
ax.set_xlabel('Sample', fontsize=11)
ax.set_ylabel('Błąd bezwzględny', fontsize=11)
ax.set_title('Błędy predykcji na zbiorze testowym', fontsize=12)
ax.grid(True, alpha=0.3, axis='y')

plt.tight_layout()
plt.show()

```



1.8 Podsumowanie Wyników

```
[9]: print("PODSUMOWANIE - LINEAR RNN DLA SUMOWANIA SEKWENCJI")
```

```

print("\n1. DANE:")
print(f"    Liczba próbek: {nb_of_samples}")
print(f"    Długość sekwencji: {sequence_len}")
print(f"    Zakres wartości: [0, 0.5, 1]")
print(f"    Zakres celów: [{t.min():.1f}, {t.max():.1f}]")

print("\n2. ARCHITEKTURA RNN:")
print(f"    Wzór: S_k = S_{(k-1)} * W_rec + X_k * W_x")
print(f"    Liczba parametrów: 2 (W_x, W_rec)")
print(f"    Liczba kroków czasowych: {sequence_len}")

print("\n3. WYNIKI TRENINGU:")
print(f"    Epok: {epochs}")
print(f"    Stopa uczenia: {learning_rate}")
print(f"    Starta strata: {loss_history[0]:.6f}")
print(f"    Finalna strata: {loss_history[-1]:.6f}")

```

```

print(f"  Redukcja straty: {((loss_history[0] - loss_history[-1]) / u
↪loss_history[0] * 100):.2f}%)"

print("\n4. WYTRENOWANE WAGI:")
print(f"  W_x = {wx:.6f}")
print(f"  W_rec = {wRec:.6f}")

print("\n5. BŁĘDY PREDYKCJI:")
S_final = forward_states(X, wx, wRec)
y_pred_final = S_final[:, -1]
errors_final = np.abs(y_pred_final - t)
print(f"  Błąd średni (MAE): {np.mean(errors_final):.6f}")
print(f"  Błąd maksymalny: {np.max(errors_final):.6f}")
print(f"  RMSE: {np.sqrt(loss_history[-1]):.6f}")

print("\n6. PRZYKŁADOWE PREDYKCJE:")
for i in range(min(5, nb_of_samples)):
    print(f"  Sample {i}: Cel={t[i]:.1f}, Predykcja={y_pred_final[i]:.1f}, u
↪Błąd={errors_final[i]:.2f}")

print("\n7. WNIOSKI:")
print("  RNN nauczyła się sumować sekwencje poprzez złożenie wejść")
print("  Gradienty backprop zostały weryfikowane numerycznie")
print("  Gradient descent efektywnie minimalizuje błąd")
print("  Wagi rekurencyjne pozwalają na akumulację informacji")
print("  BPTT (Backprop Through Time) propaguje gradient wstecz przez czas")

```

PODSUMOWANIE – LINEAR RNN DLA SUMOWANIA SEKWENCJI

1. DANE:

Liczba próbek: 30
Długość sekwencji: 20
Zakres wartości: [0, 0.5, 1]
Zakres celów: [6.0, 14.0]

2. ARCHITEKTURA RNN:

Wzór: $S_k = S_{(k-1)} * W_{rec} + X_k * W_x$
Liczba parametrów: 2 (W_x , W_{rec})
Liczba kroków czasowych: 20

3. WYNIKI TRENINGU:

Epok: 400
Stopa uczenia: 0.005
Starta strata: 96.352116
Finalna strata: 1.697029
Redukcja straty: 98.24%

4. WYTRENOWANE WAGI:

W_x = 0.775839

W_rec = 1.037457

5. BŁĘDY PREDYKCJI:

Błąd średni (MAE): 1.309174

Błąd maksymalny: 2.309641

RMSE: 1.302701

6. PRZYKŁADOWE PREDYKCJE:

Sample 0: Cel=8.5, Predykcja=9.7, Błąd=1.24

Sample 1: Cel=9.0, Predykcja=9.9, Błąd=0.92

Sample 2: Cel=10.0, Predykcja=11.1, Błąd=1.13

Sample 3: Cel=10.0, Predykcja=11.6, Błąd=1.56

Sample 4: Cel=10.0, Predykcja=11.6, Błąd=1.55

7. WNIOSKI:

RNN nauczyła się sumować sekwencje poprzez złożenie wejść

Gradienty backprop zostały weryfikowane numerycznie

Gradient descent efektywnie minimalizuje błąd

Wagi rekurencyjne pozwalają na akumulację informacji

BPTT (Backprop Through Time) propaguje gradient wstecz przez czas